分布式系统
Distributed Systems

陈鹏飞
计算机学院
chchenpf7@mail.sysu.edu.cn
办公室：学院楼310
主页：http://sdcs.sysu.edu.cn/node/3747

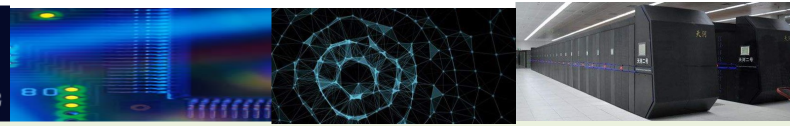

第三讲 — 分布式中的进程和虚拟化

大纲

1 分布式系统中的线程

进程

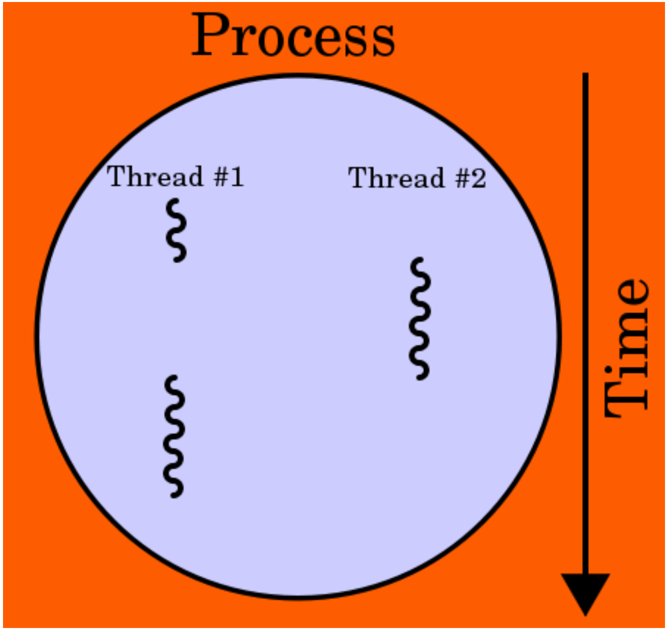

- 何为进程？
- 何为线程？
- 操作系统如何管理进程？

初始化、分配资源、调度、销毁

分布式系统中的线程

➢ 基本思想：

在物理处理器上用软件创建虚拟处理器：

- 处理器： 提供和运行一系列指令集合的硬件平台；
- 线程： 一个最小的可执行一系列指令的软件处理器。 保存线程的上下文意味着终止线程当前的执行，在其他时刻装载保存的线程上下文后，线程可以继续执行；
- 进程：包含多个线程的软件处理器，线程需要在进程的上下文中执行。

上下文切换

➢ 上下文

系统运行过程中的一系列状态，状态的含义因系统的不同而不同

- 处理器上下文

  处理器用于运行一系列指令的保存在寄存器中的最小数据集合（如：栈指针、地址寄存器、程序计数器）；

- 线程上下文

  用于执行一系列指令的保存在寄存器和内存中的最小的数据集合（如：处理器上下文、状态等）；

- 进程上下文

  用于执行线程的保存在寄存器和内存中的最小的数据集合（线程上下文、**MMU**寄存器值、**TLB**）

上下文切换

- 观察发现
  - 线程共享相同的地址空间。 线程上下文的切换可以独立于操作系统；
  - 一般来讲进程之间的切换要更复杂、代价更高，因为需要陷入到OS内核才能完成；
  - 创建和销毁线程的代价要远远小于对进程的创建和销毁；

为什么要利用线程

主要的原因：

- 避免不必要的阻塞： 单线程的进程在进行I/O操作的时候会被阻塞； 在多线程的进程中，操作系统可以将CPU切换到进程的另外一个线程；
- 更好地发挥并行性：一个具有多线程的进程可以在多核或者多处理器的CPU上并行执行；
- 避免进程上下文切换：架构大型应用的时候不是利用多个进程而是多个线程；

避免进程切换

➢ 避免昂贵的上下文切换

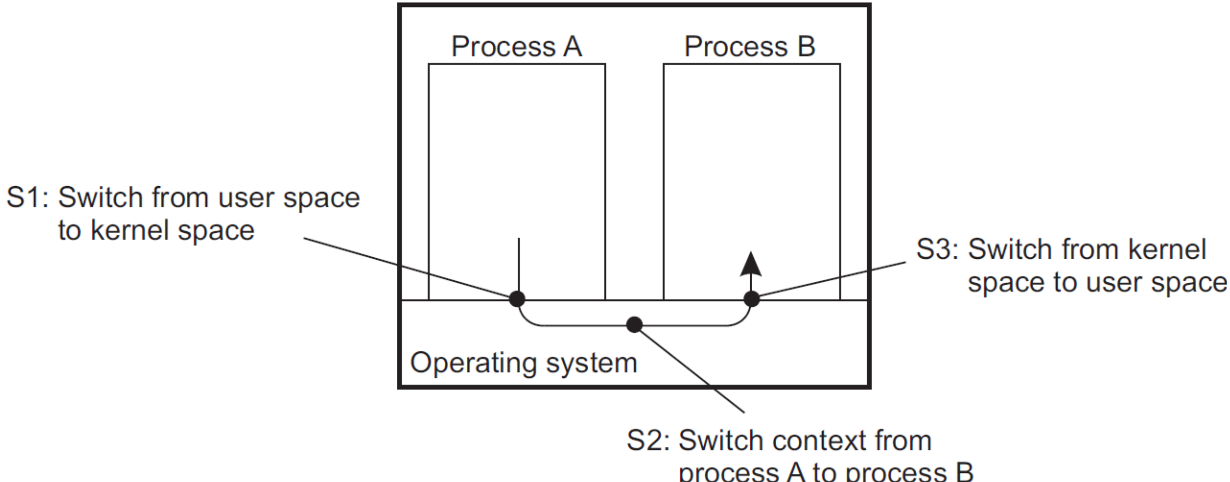

- ◻ 多个线程利用相同的地址空间：更容易出错；
- ◻ 在线程使用内存时，没有来自OS/HW的保护；平衡
- ◻ 线程的上下文切换比进程的上下文切换要快得多？；

上下文切换的代价

考虑简单的时钟中断处理器：

- 直接代价：用于实际切换和执行中断处理代码的时间；
- 间接代价：其他代价，比较常见的是cache刷新的时间；

上下文切换导致的间接代价：

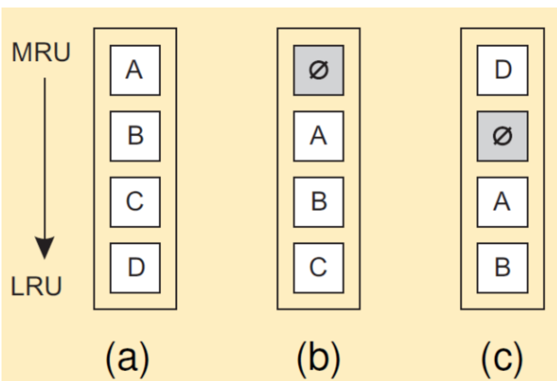

(a) 在上下文切换之前；
(b) 在上下文切换之后；
(c) 在访问区块D之后；

代价高达 80%

线程的实现

- 线程的实现方式
  - 往往以线程包的形式存在；
  - 完全在用户空间下创建线程库；
  - 由内核来掌管线程并进行调度；
- 用户级线程
  - 好处：上下文切换代价小；
  - 缺陷：线程阻塞 -> 进程阻塞；

用户级别的线程

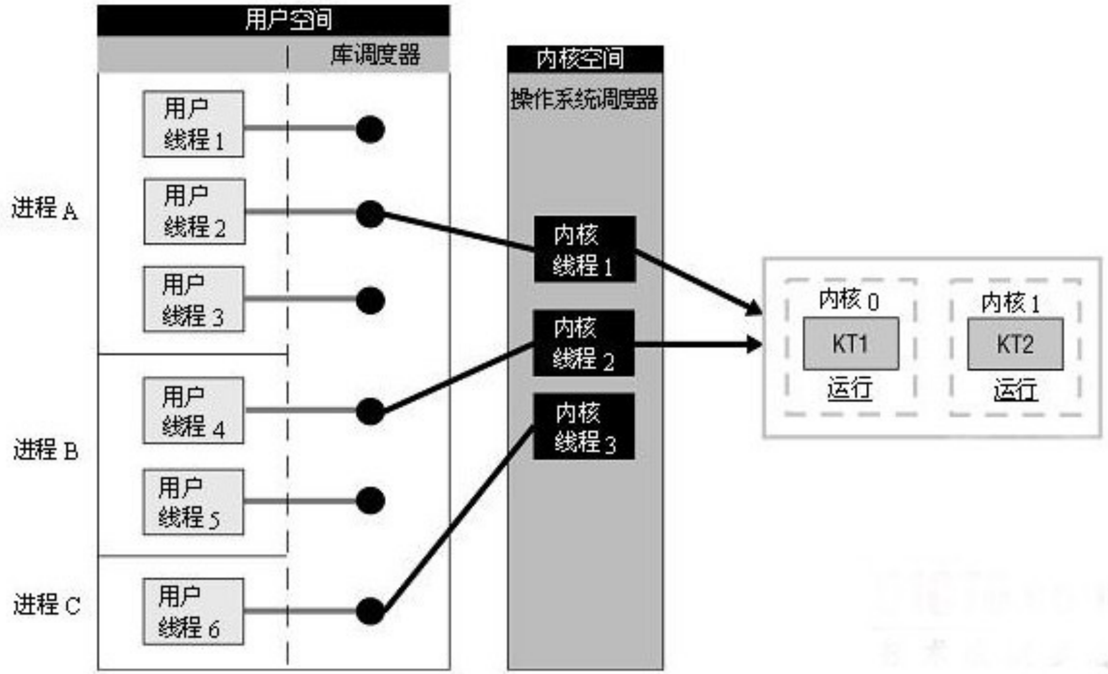
用户空间
库调度器
内核空间
操作系统调度器
进程 A
进程 B
进程 C
用户线程 1
用户线程 2
用户线程 3
用户线程 4
用户线程 5
用户线程 6
内核线程 1
内核线程 2
内核线程 3
内核 0
KT1
运行
内核 1
KT2
运行

内核级别的线程

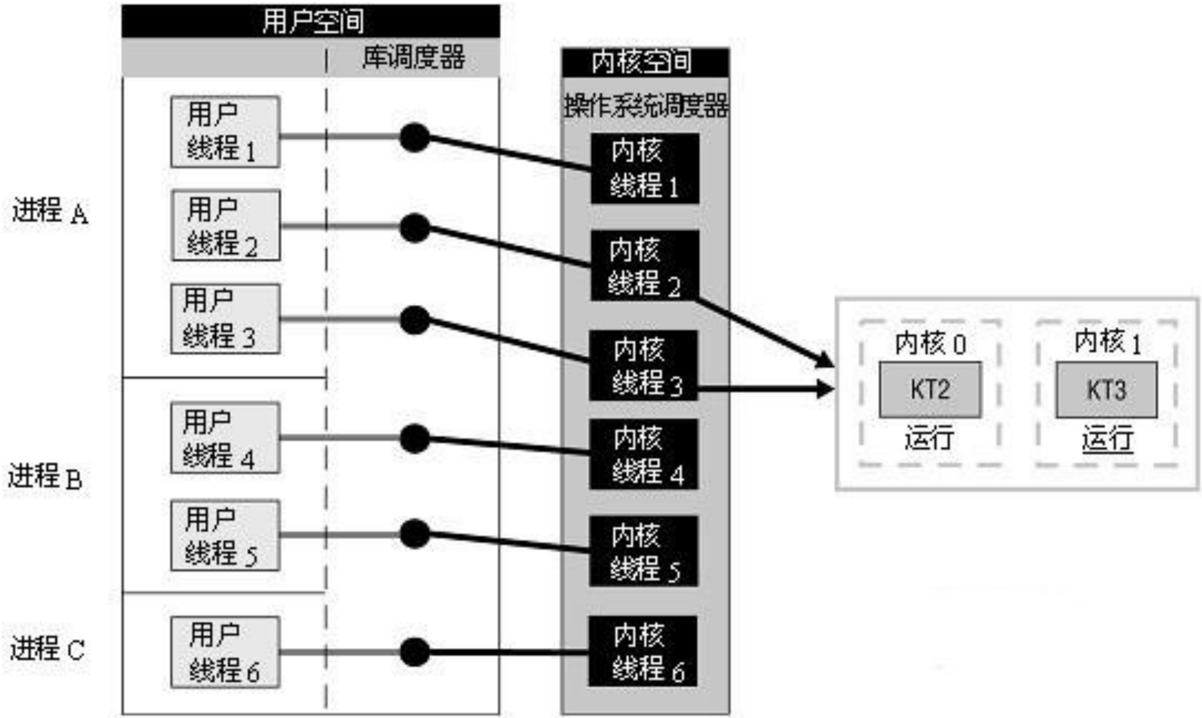
用户空间
库调度器
内核空间
操作系统调度器
进程 A
进程 B
进程 C
用户线程 1
用户线程 2
用户线程 3
用户线程 4
用户线程 5
用户线程 6
内核线程 1
内核线程 2
内核线程 3
内核线程 4
内核线程 5
内核线程 6
内核 0
KT2
运行
内核 1
KT3
运行

混合级别的线程

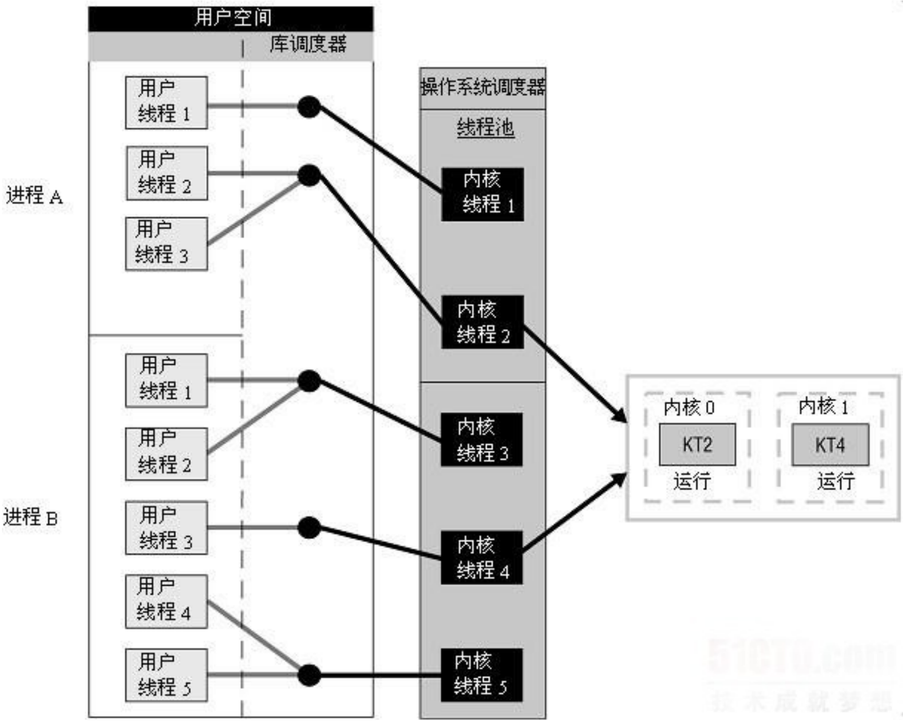
用户空间
库调度器
进程 A
用户
线程 1
用户
线程 2
用户
线程 3
进程 B
用户
线程 1
用户
线程 2
用户
线程 3
用户
线程 4
用户
线程 5
操作系统调度器
线程池
内核
线程 1
内核
线程 2
内核
线程 3
内核
线程 4
内核
线程 5
内核 0
KT2
运行
内核 1
KT4
运行

线程和操作系统

- **内核解决方案**

基本的想法是在内核中实现软件包，这也就意味着所有的操作变成系统调用；

- 用于阻塞线程的操作就不再是问题了，内核会在同一个进程中调度另外一个可用的线程；
- 处理外部事件也变得简单了：内核（捕捉所有的事件）直接调度与线程相关的事件；
- 存在的问题是效率，因为每个线程操作都需要陷入到内核；

- 结论

尽可能融合用户级别和内核级别的线程，发挥各自的优势。但是，事实上这种做法带来的性能提升也难以弥补其复杂性带来的困难。

轻量级进程（LWP）

➢ 基本思想

引入一种两层线程方法：轻量级的进程 (LWP) 能够执行用户空间的线程；

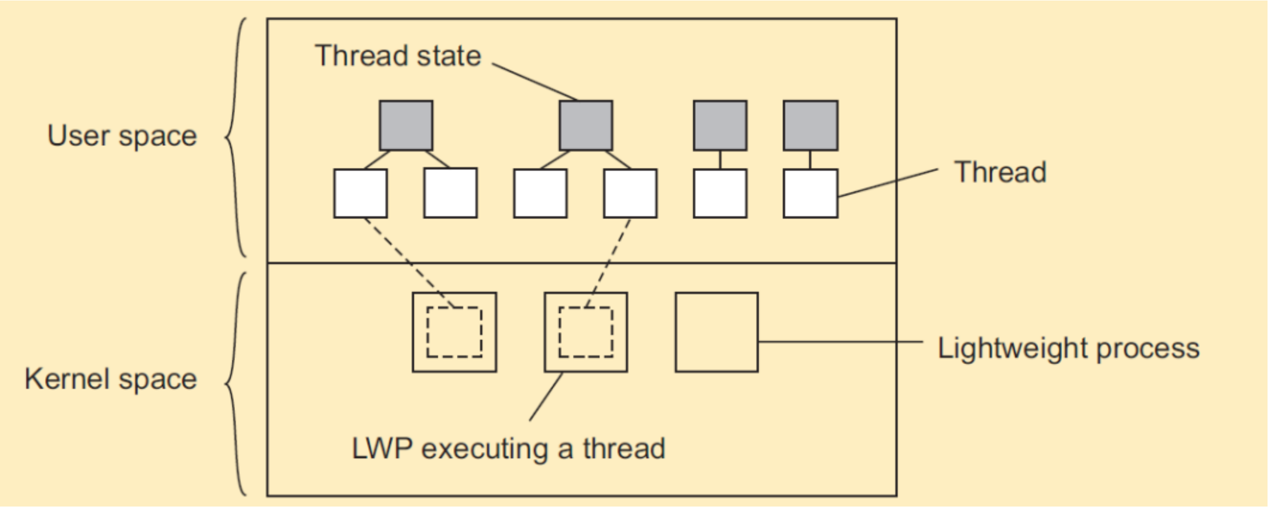

轻量级进程（LWP）

- 主要的操作
  - 用户级的线程执行系统调用 => LWP执行相应的操作，同时该线程被挂起。线程维持绑定在该LWP上；
  - 内核调度负责调度另外一个LWP，该LWP绑定了一个活跃线程。注意，这个线程可以切换到用户空间中的另外的活跃线程；
  - 一个线程调用阻塞用户层的操作 => 上下文切换到一个运行的线程，并绑定到相同的LWP；
  - 当没有线程调用时， LWP 保持空闲甚至有可能被内核清除、回收；

在客户端使用多线程

- **多线程在分布式系统中的重要意义**
- **多线程的Web客户端**

  隐藏了网络的延迟；

  - Web浏览器扫描到达的HTML页面，发现需要获取更多页面；
  - 每一个页面由一个特定的线程获取，每个线程执行HTTP请求；
  - 随着文件的到达，浏览器将这些文件展示出来；
- **服务器之间多个请求-响应调用**
  - 客户端同时产生多个调用，每一个线程负责一个调用；
  - 之后，客户端等待结果返回
  - 注意： 如果调用的不同的服务器，将会得到线性加速；

多线程客户端是否有用？

Thread-level parallelism: TLP

Let c_i denote the fraction of time that exactly i threads are being executed simultaneously.

$$TLP = \frac{\sum_{i=1}^{N} i \cdot c_i}{1 - c_0}$$

with N the maximum number of threads that (can) execute at the same time.

Practical measurements

A typical Web browser has a TLP value between 1.5 and 2.5 $\Rightarrow$ threads are primarily used for logically organizing browsers.

多线程服务器

➢ 提高性能

- 启动一个线程远比启动一个进程代价要小很多；
- 单线程服务很难在多处理器系统中实现 scale-up（纵向扩展）；
- 与多线程客户端相呼应：通过并行响应请求隐藏网络延迟；

➢ 更好的结构

- 大部分服务器都具有较高的I/O需求，使用简单容易理解的阻塞调用可以简化整体结构；
- 多线程的程序的代码数量较少，比较容易理解，因为控制流被简化了；

多线程服务器举例：文件服务器

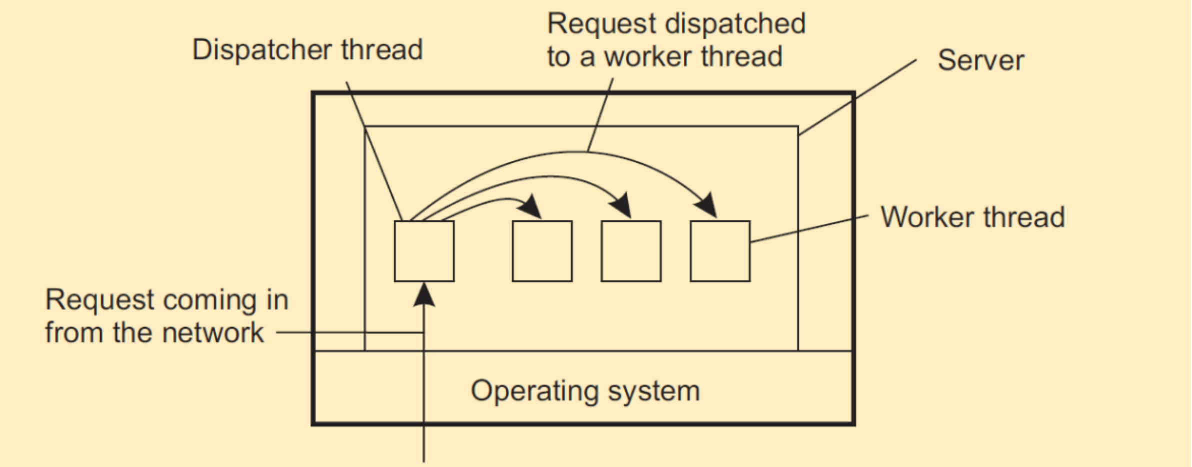

模型	特征
多线程	并行，使用会导致阻塞的系统调用
单线程进程	非并行，使用会导致阻塞的系统调用
有限状态机	并行，使用非阻塞系统调用

图 3.4　构建服务器的 3 种方式

虚拟化（Virtualization）

- 观察发现

虚拟化（**软硬件的多路复用**）非常重要：

- 硬件比软件变化的快；
- 需要灵活的可移植性和代码迁移；
- 失效和攻击隔离

虚拟化（Virtualization）

➢ 主要原理：模拟接口

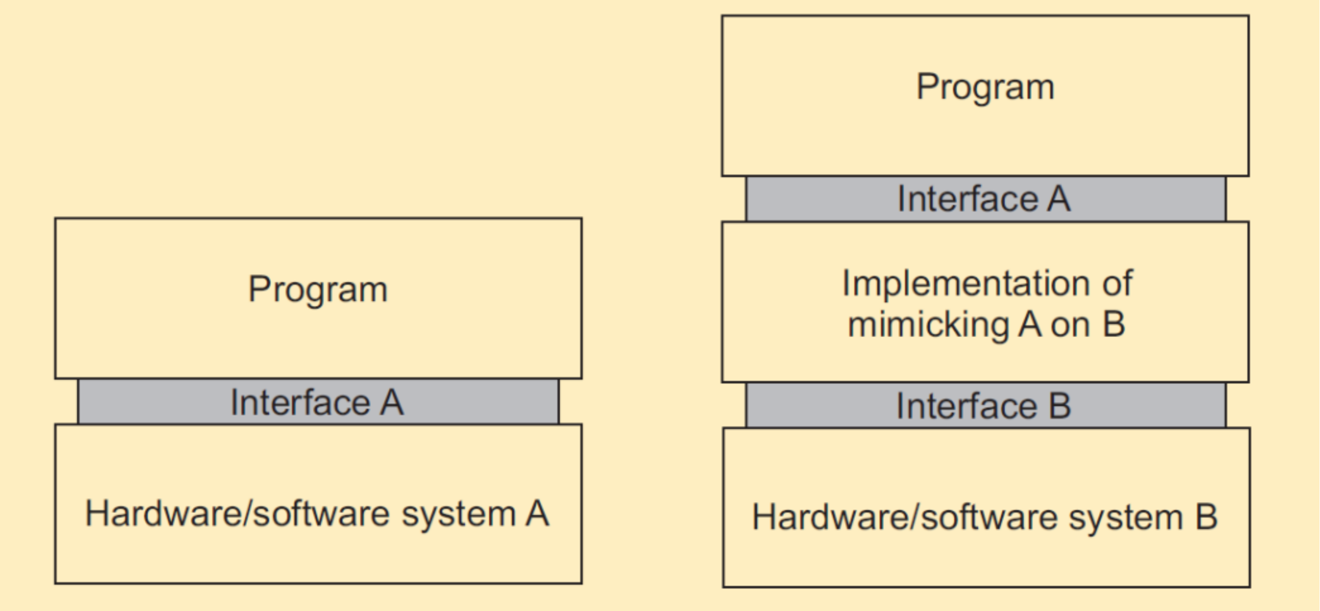

模拟接口

> ➢ 三个层次上的四种类型的接口

- **指令集架构：**一系列的机器指令，主要分为两类：
  - a. 特权指令：允许操作系统执行的指令；
  - b. 通用指令：可以被任何程序执行的指令；
- 系统调用
  由操作系统提供的函数；
- 库函数调用，也称为**应用程序接口（API）**

虚拟化的不同方式

(a) 进程虚拟机 (Process VM)、(b) 原生虚拟机监控器 (Native VMM)、(c) 主机虚拟机监控器 (Hosted VMM)

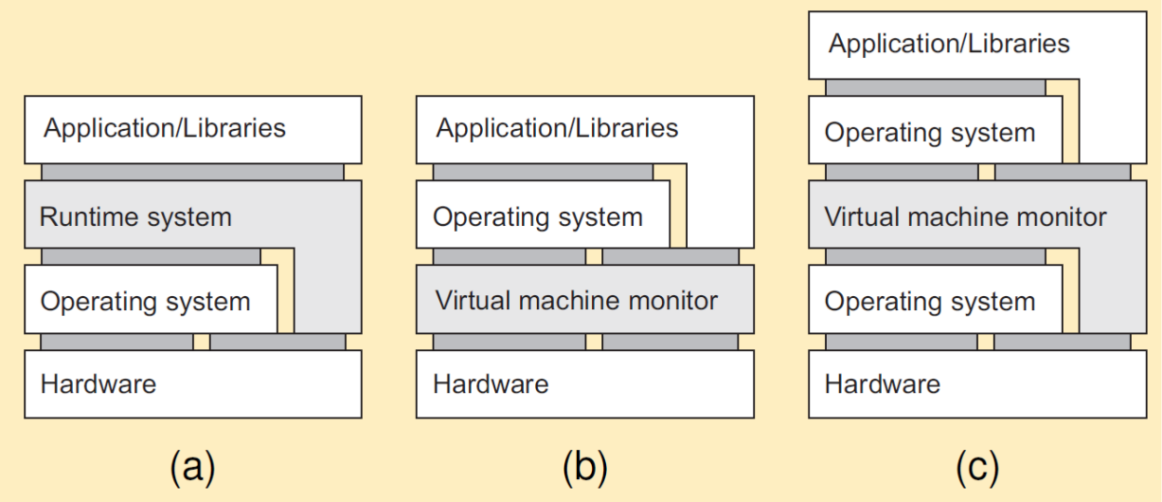

区别：(a) 分离的指令集合，实际是运行在操作系统之上的解释器（JVM）或者模拟器（Qemu）；（b）底层的指令，同时具有跑在硬件上的最小的操作系统；（c）底层指令，但是需要一个完整的OS；

进一步了解虚拟机：性能

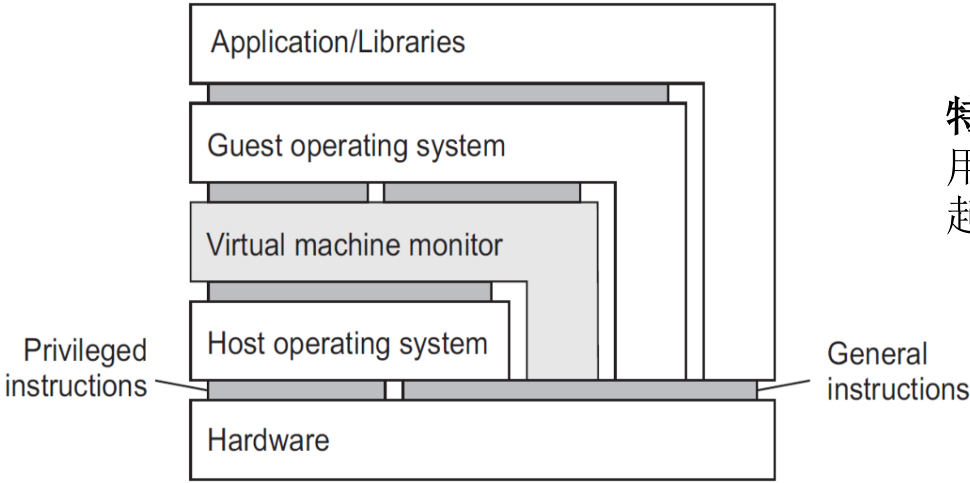

特权指令：当且仅当在用户模式下执行时，引起操作系统陷入；

非特权指令：其他所有指令

特殊指令：

控制敏感性指令：可能影响到机器配置的指令（如：寄存器重定位**或者中断表）**

行为敏感性指令：指令效果由上下文确定；

虚拟化的条件

- 采用虚拟化的必要条件

对于任何通用计算机，如果敏感指令集是特权指令的子集，则可以构建虚拟机监控器；

- 问题：条件并不总是被满足

存在这样的敏感指令集，这些指令集在用户空间执行，但是不会引起操作系统的陷入（POPF）；

- 解决方案：

- 模拟所有指令；
- 包装非特权敏感指令，将其交给VMM控制执行；
- 半虚拟化（Paravirtualization）：修改客户OS，要么阻止非特权的敏感指令，或者将其变为非敏感指令（也就是改变上下文）；

Docker

什么是容器？

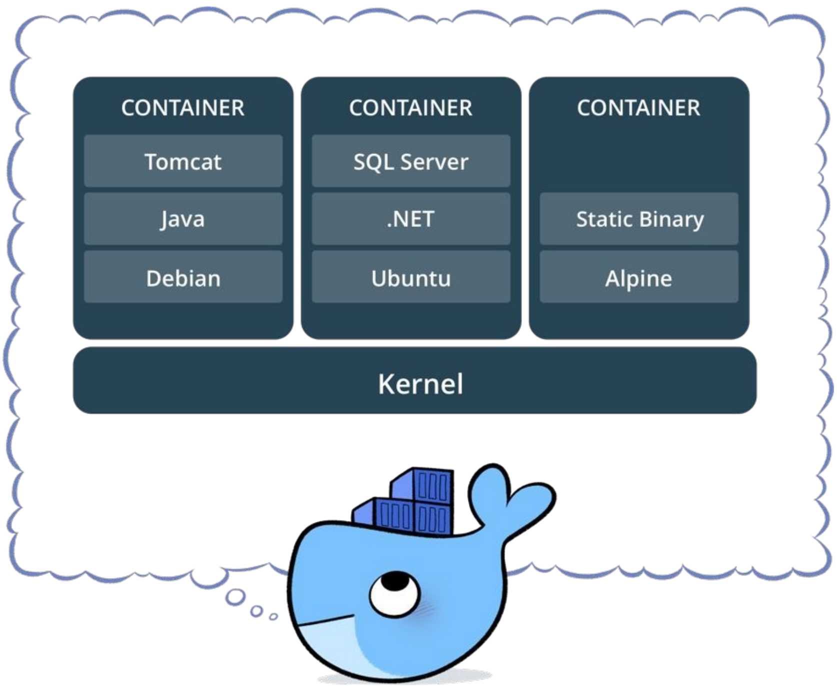

- Standardized packaging for software and dependencies
- Isolate apps from each other
- Share the same OS kernel
- Works for all major Linux distributions
- Containers native to Windows Server 2016

Docker

- 镜像 ---镜像就相当于集装箱，docker 将所有app都标准化，需要使用就拉取镜像。
- 仓库---仓库就相当于超级码头，docker将所有镜像存储于仓库。
- 容器---容器就是应用运行的地方，每个容器是独立的。这就体现了它的隔离性；

Docker Image
Example: Ubuntu with Node.js and Application Code

Docker Container
Created by using an image. Runs your application.

Docker 镜像

docker镜像是一系列文件，它起源于linux联合文件系统，通过分层实现镜像文件的存储。

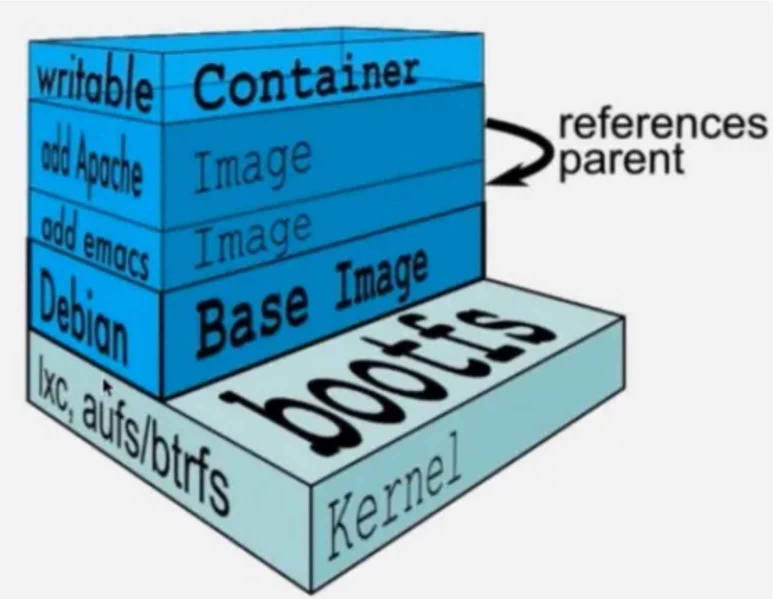

Docker VS VM

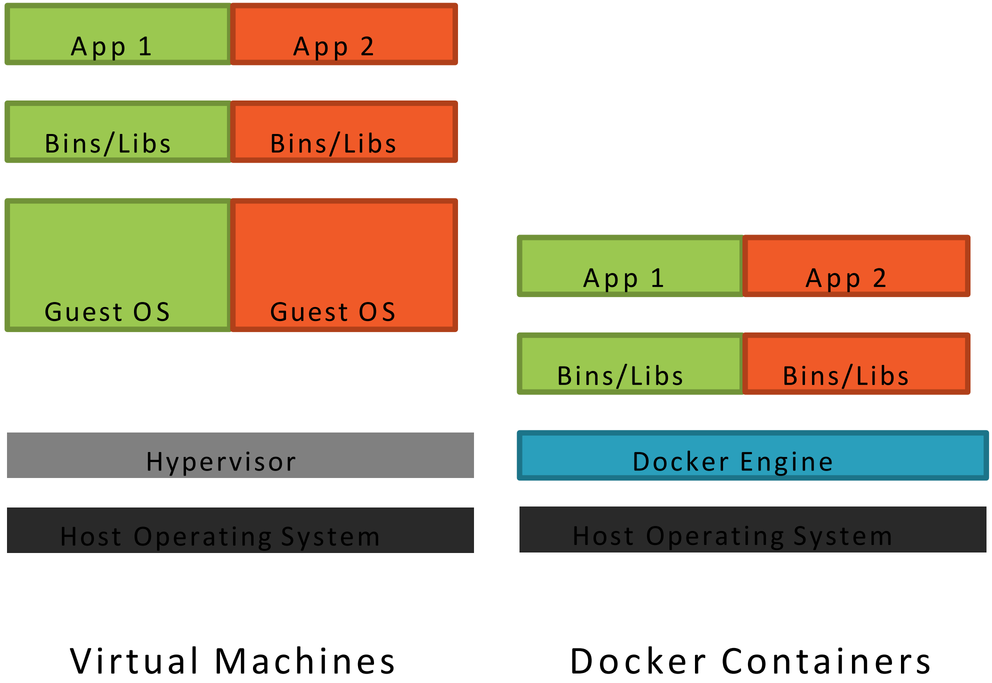
App 1
App 2
Bins/Libs
Bins/Libs
Guest OS
Guest OS
Hypervisor
Host Operating System
App 1
App 2
Bins/Libs
Bins/Libs
Docker Engine
Host Operating System
Virtual Machines
Docker Containers

Docker

What Is Docker?

Lightweight, open, secure platform

- Simplify building, shipping, running a
  pps
- Runs natively on Linux or Windows S
  erver
- Runs on Windows or Mac Develop
  ment machines (with a virtual mac
  hine)
- Relies on "images" and "containers"

Docker的创建、发布、运行过程

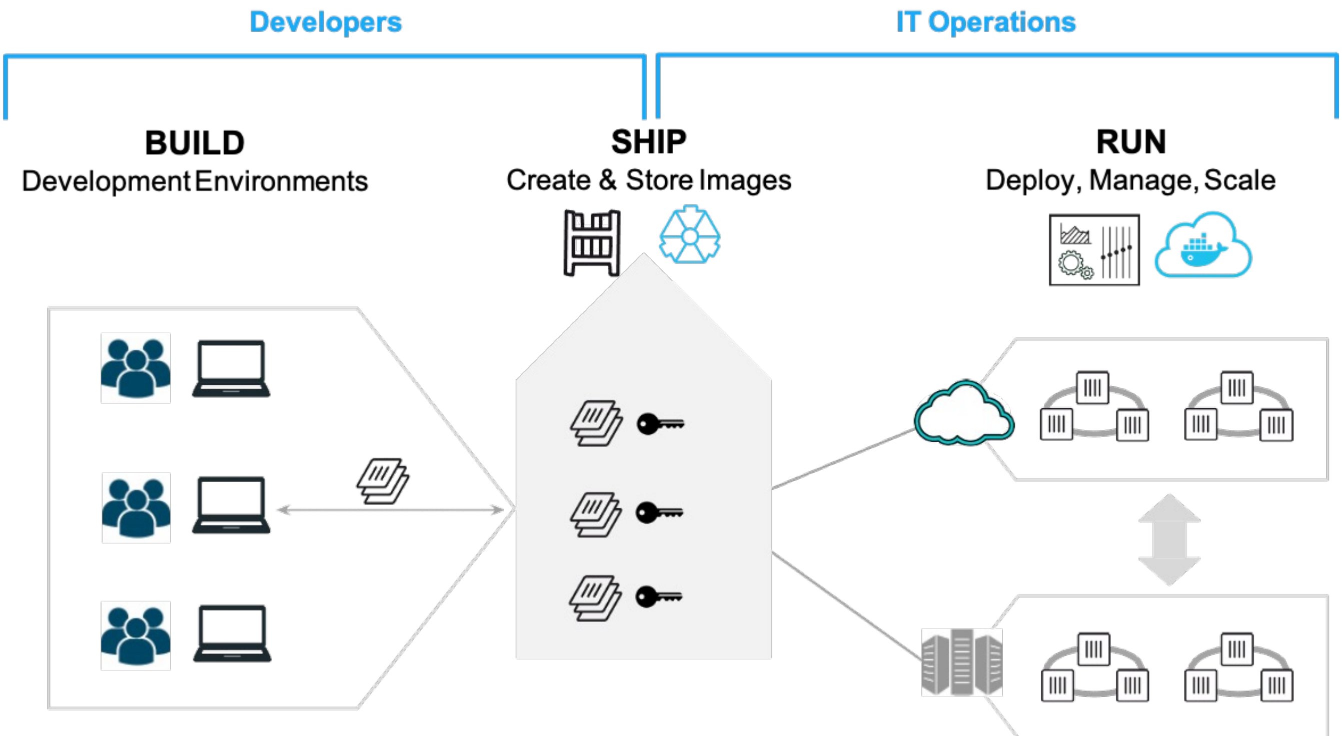

Docker相关的词汇

Docker Image

The basis of a Docker container. Represents a full application

Docker Container

The standard unit in which the application service resides and executes

Docker Engine

Creates, ships and runs Docker containers deployable on a physical or virtual, host locally, in a datacenter or cloud service provider

Registry Service (Docker Hub(Public) or Docker Trusted Registry(Private))

Cloud or server based storage and distribution service for your images

Docker相关的命令

```
$ docker image pull node:latest

$ docker image ls

$ docker container run -d -p 5000:5000 --name node node:latest

$ docker container ps

$ docker container stop node(or <container id>)

$ docker container rm node (or <container id>)

$ docker image rmi (or <image id>)

$ docker build -t node:2.0 .

$ docker image push node:2.0

$ docker --help
```

Dockerfile

Dockerfile

```
# Create image based on the official Node 6 image from dockerhub
FROM node:latest

# Create a directory where our app will be placed
RUN mkdir -p /usr/src/app

# Change directory so that our commands run inside this new directory
WORKDIR /usr/src/app

# Copy dependency definitions
COPY package.json /usr/src/app

# Install dependecies
RUN npm install

# Get all the code needed to run the app
COPY . /usr/src/app

# Expose the port the app runs in
EXPOSE 4200

# Serve the app
CMD ["npm", "start"]
```

- Instructions on how to build a Docker image
- Looks very similar to “native” commands
- Important to optimize your Dockerfile

客户-服务器之间的交互

客户机器主要是让个人用户和远程服务器交互。主要包含两种模式：1、对于每种远程服务，客户机都有一个独立的网络模块联系这些服务；2、通过一个方便统一的用户接口来对远程服务直接访问；

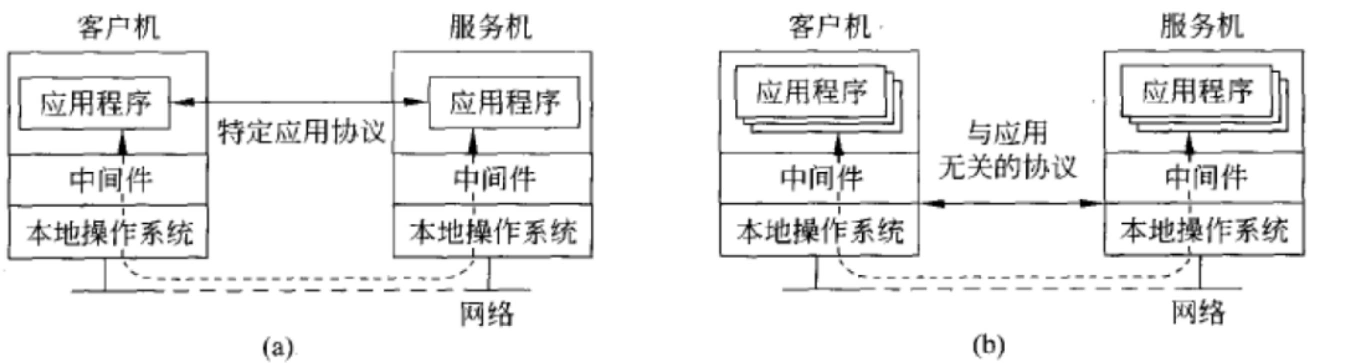

图 3.8

(a) 带自用协议的网络连接的应用程序；(b) 允许访问远程应用程序的通用解决方案

样例： X windows系统

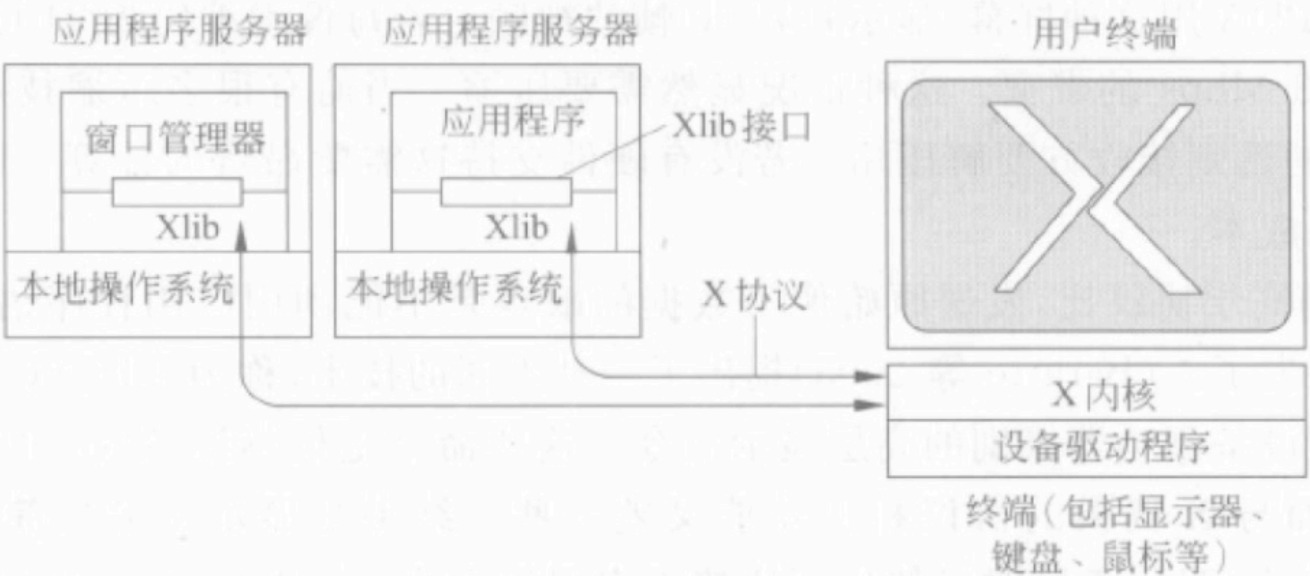

图 3.9 X Window 系统基本组织结构

提高X Windows系统性能

➢ 实际观察

- 应用程序的逻辑和用户接口之间没有清晰的界限；
- 应用程序与X内核之间的交互倾向于采用同步模式；

➢ 改进方法

- 应用程序完全控制显示，可以到像素级别（VNC）；
- 提供几种高层次的显示操作；
- 压缩、增量传输；

客户端软件

客户端软件包含用于获得分布式透明性的组件

- 访问透明性：客户端拥有用于 RPC访问的存根；
- 位置/迁移的透明性：让客户端记录服务器的实际位置；
- 副本透明性：客户端存根多个副本的调用

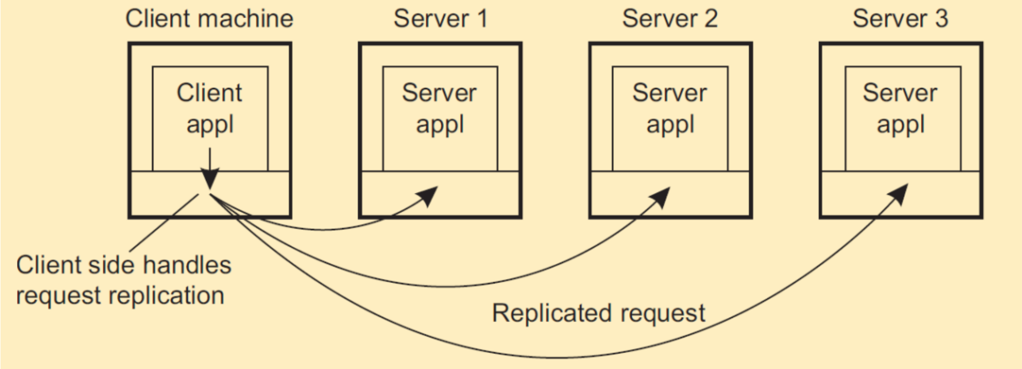

- 故障透明性：经常放在客户端（用于屏蔽服务器和通信问题）

服务器软件：常见设计问题

- **基本模型：**

  服务器是实现特定服务的进程，这些服务是为一组客户提供的。本质上，每个服务器的组织方式都一样，等待来自客户的请求，随后负责处理该请求。

服务器的组织方式

- 两种基本类型
  - 迭代服务器（Iterative server）： 服务器顺序处理到达的请求；
  - 并发服务器（Concurrent server）：利用分派器（dispatcher），选择到达的请求并将它传递给分离的线程或者进程处理；
- 观察发现

并发服务器是一种常见的类型：他们能够处理多个请求，特别是针对某些阻塞性的操作；

服务器连接

```
EtherNet/IP-2   44818/tcp EtherNet-IP-2  # EtherNet/IP messaging
EtherNet/IP-2   44818/udp EtherNet-IP-2  # EtherNet/IP messaging
m3da            44900/tcp               # M3DA (efficient machine-to-machine com
munication)
m3da-disc       44900/udp               # M3DA Discovery (efficient machine-to-m
achine communication)
asmp            45000/tcp               # NSi AutoStore Status Monitoring Protoc
ol data transfer
asmp-mon        45000/udp               # NSi AutoStore Status Monitoring Protoc
ol device monitoring
asmps           45001/tcp               # NSi AutoStore Status Monitoring Protoc
ol secure data transfer
synctest        45045/tcp               # Remote application control
invision-ag     45054/tcp               # InVision AG
invision-ag     45054/udp               # InVision AG
eba             45678/tcp               # EBA PRISE
eba             45678/udp               # EBA PRISE
dai-shell       45824/tcp               # Server for the DAI family of client-se
rver products
qdb2service     45825/tcp               # Qpuncture Data Access Service
qdb2service     45825/udp               # Qpuncture Data Access Service
ssr-servermgr   45966/tcp               # SSRServerMgr
ssr-servermgr   45966/udp               # SSRServerMgr
sp-remotetablet 46998/tcp               # connection between computer and a sign
ature tablet
mediabox        46999/tcp               # MediaBox Server
mediabox        46999/udp               # MediaBox Server
mbus            47000/tcp               # Message Bus
mbus            47000/udp               # Message Bus
winrm           47001/tcp               # Windows Remote Management Service
jvl-mactalk     47100/udp               # Configuration of motors conneced to in
dustrial ethernet
dbbrowse        47557/tcp               # Databeam Corporation
dbbrowse        47557/udp               # Databeam Corporation
directplaysrvr  47624/tcp               # Direct Play Server
directplaysrvr  47624/udp               # Direct Play Server
ap              47806/tcp               # ALC Protocol
ap              47806/udp               # ALC Protocol
bacnet          47808/tcp               # Building Automation and Control Networ
ks
bacnet          47808/udp               # Building Automation and Control Networ
ks
nimcontroller   48000/tcp               # Nimbus Controller
nimcontroller   48000/udp               # Nimbus Controller
nimspooler      48001/tcp               # Nimbus Spooler
nimspooler      48001/udp               # Nimbus Spooler
nimhub          48002/tcp               # Nimbus Hub
nimhub          48002/udp               # Nimbus Hub
nimgtw          48003/tcp               # Nimbus Gateway
nimgtw          48003/udp               # Nimbus Gateway
```

静态端口配置：/proc/services

```
tcp        0      0 127.0.0.1:43984         127.0.0.1:2379          ESTABLISHED
tcp        0      0 127.0.0.1:10252         127.0.0.1:57092         TIME_WAIT
tcp        0      0 127.0.0.1:2379          127.0.0.1:43908         ESTABLISHED
tcp        0      0 222.200.180.178:40316   222.200.180.178:9999    ESTABLISHED
tcp        0      0 222.200.180.178:39780   222.200.180.178:6443    ESTABLISHED
tcp        0      0 222.200.180.178:60560   222.200.180.178:9090    ESTABLISHED
tcp        0      0 222.200.180.178:9090    222.200.180.178:60564   ESTABLISHED
tcp        0      0 127.0.0.1:2379          127.0.0.1:45296         TIME_WAIT
tcp        0      0 127.0.0.1:43992         127.0.0.1:2379          ESTABLISHED
tcp        0      0 127.0.0.1:43918         127.0.0.1:2379          ESTABLISHED
tcp        0      0 222.200.180.178:39876   222.200.180.178:6443    ESTABLISHED
tcp        0      0 222.200.180.178:39920   222.200.180.178:6443    ESTABLISHED
tcp        0      0 127.0.0.1:2379          127.0.0.1:43938         ESTABLISHED
tcp        0      0 222.200.180.178:39802   222.200.180.178:6443    ESTABLISHED
tcp        0      0 222.200.180.178:36878   222.200.180.178:3306    ESTABLISHED
tcp        0      0 222.200.180.178:9090    222.200.180.178:60556   ESTABLISHED
tcp        0      0 127.0.0.1:43946         127.0.0.1:2379          ESTABLISHED
tcp        0      0 127.0.0.1:2379          127.0.0.1:43898         ESTABLISHED
tcp        0      0 10.96.0.1:59266         10.96.0.9:8081          TIME_WAIT
tcp        0      0 127.0.0.1:2379          127.0.0.1:43880         ESTABLISHED
tcp        0      0 127.0.0.1:10251         127.0.0.1:60262         TIME_WAIT
tcp        0      0 127.0.0.1:43948         127.0.0.1:2379          ESTABLISHED
tcp        0      0 222.200.180.178:60556   222.200.180.178:9090    ESTABLISHED
tcp        0      0 222.200.180.178:35376   10.96.0.1:443           ESTABLISHED
tcp        0      0 127.0.0.1:2379          127.0.0.1:43888         ESTABLISHED
tcp        0      0 127.0.0.1:2379          127.0.0.1:43946         ESTABLISHED
tcp        0      0 222.200.180.178:60564   222.200.180.178:9090    ESTABLISHED
tcp        0      0 127.0.0.1:43990         127.0.0.1:2379          ESTABLISHED
tcp        0      0 127.0.0.1:10251         127.0.0.1:60306         TIME_WAIT
tcp        0      0 127.0.0.1:43876         127.0.0.1:2379          ESTABLISHED
tcp6       0      0 222.200.180.178:6443    222.200.180.184:38702   ESTABLISHED
tcp6       0      0 127.0.0.1:6443          127.0.0.1:43500         ESTABLISHED
tcp6       0      0 222.200.180.178:6443    10.96.0.9:35037         ESTABLISHED
tcp6       0      0 222.200.180.178:3306    222.200.180.178:36878   ESTABLISHED
tcp6       0      0 222.200.180.178:6443    222.200.180.178:35376   ESTABLISHED
tcp6       0      0 222.200.180.178:6443    222.200.180.183:55776   ESTABLISHED
tcp6       0      0 222.200.180.178:6443    222.200.180.178:42364   ESTABLISHED
tcp6       0      0 222.200.180.178:6443    222.200.180.178:39898   ESTABLISHED
tcp6       0      0 222.200.180.178:3306    222.200.180.178:36220   ESTABLISHED
tcp6       0      0 222.200.180.178:6443    222.200.180.178:54102   ESTABLISHED
tcp6       0      0 222.200.180.178:6443    222.200.180.179:34888   ESTABLISHED
tcp6       0      0 222.200.180.178:6443    222.200.180.184:38690   ESTABLISHED
tcp6       0      0 222.200.180.178:6443    222.200.180.178:39802   ESTABLISHED
tcp6       0      0 222.200.180.178:6443    222.200.180.178:54086   ESTABLISHED
tcp6       0      0 222.200.180.178:6443    222.200.180.178:39942   ESTABLISHED
tcp6       0      0 222.200.180.178:6443    222.200.180.178:39780   ESTABLISHED
tcp6       0      0 222.200.180.178:6443    222.200.180.178:39972   ESTABLISHED
tcp6       0      0 222.200.180.178:6443    222.200.180.178:39168   ESTABLISHED
tcp6       0      0 222.200.180.178:6443    222.200.180.178:39604   ESTABLISHED
tcp6       0      0 222.200.180.178:6443    222.200.180.183:43114   ESTABLISHED
```

动态连接查询：netstat -n

服务器连接

- 观察发现：大多数服务都跟一个特定的端口绑定在一起

ftp-data	20	File Transfer [Default Data]
ftp	21	File Transfer [Control]
telnet	23	Telnet
smtp	25	Simple Mail Transfer
www	80	Web (HTTP)

- 动态分配一个端口

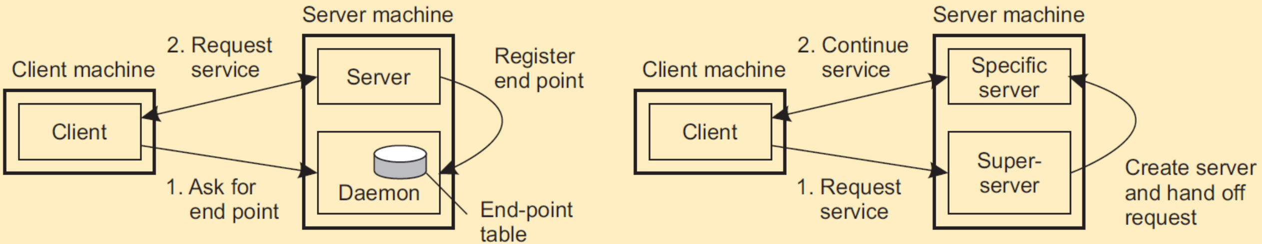

两者的区别

带外通信（out of band communication）

➢ 问题

在服务器已经接收了服务器请求后，是否有可能中断服务器的运行？

➢ 解决方案1： 利用一个分开的端口用于紧急数据通信

- 服务器拥有一个分离的线程或者进程用于紧急通信；
- 紧急信息到达 => 相关联的请求暂时挂起；
- 注意：我们需要 OS 支持基于优先级的调度策略；

➢ 解决方案2： 利用传输层的机制

- 样例：TCP 允许在同一个连接中传输紧急信息；
- 利用OS的信号机制捕捉紧急信息；

服务器和状态

- 无状态服务器（Stateless servers）

  在处理完请求后，从来不保存关于客户端的精确的信息；

  - 不记录一个文件是否被打开（文件请求完成就关闭）；
  - 不保证清空客户端的cache；
  - 不去追踪客户的信息；

- 结果
  - 客户端和服务器完全独立；
  - 由于客户端或者服务器的宕机导致的状态不一致减少；
  - 由于服务器不能预测客户端的行为，可能导致性能下降；

服务器和状态

- 有状态服务器（Stateful servers）

  记录客户端的状态信息：

  - 记录客户端打开的文件，这样可以提前实现预取；
  - 知道客户端缓存了哪些数据，允许客户端在本地保存共享数据的备份；

- 观察发现

  - 有状态的服务器的性能非常高；
  - 可靠性问题是一个主要的问题；

服务器集群

➢ 常见的组织结构

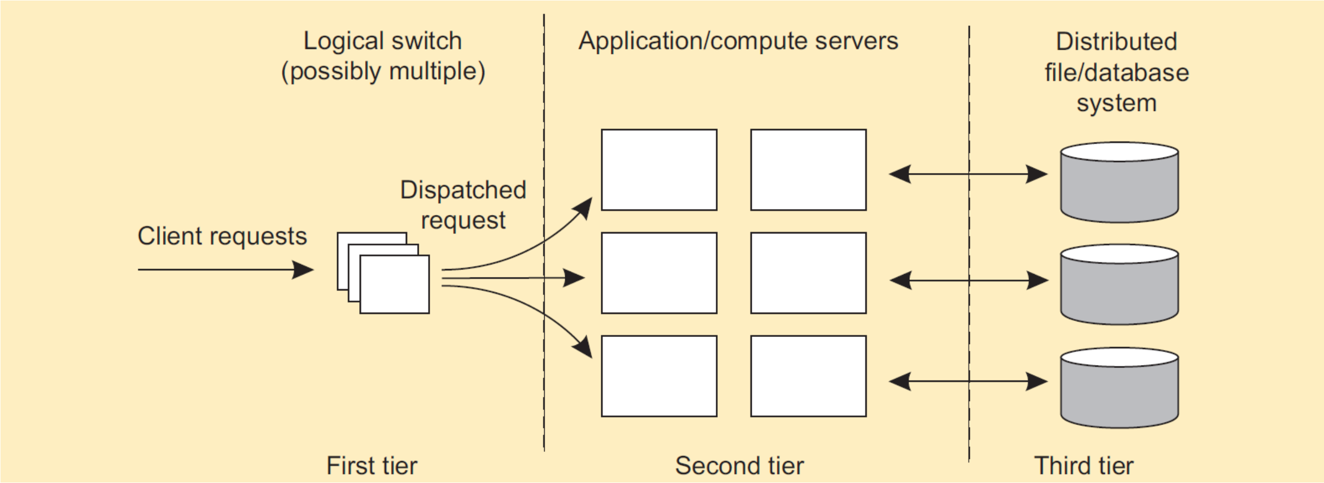

➢ 关键单元

- 第一层主要用于请求分发 （掩盖分布式系统的分布式特性）

请求处理

- 观察

  - 让第一层处理所有的出入集群的通信会导致性能瓶颈；

- 观察

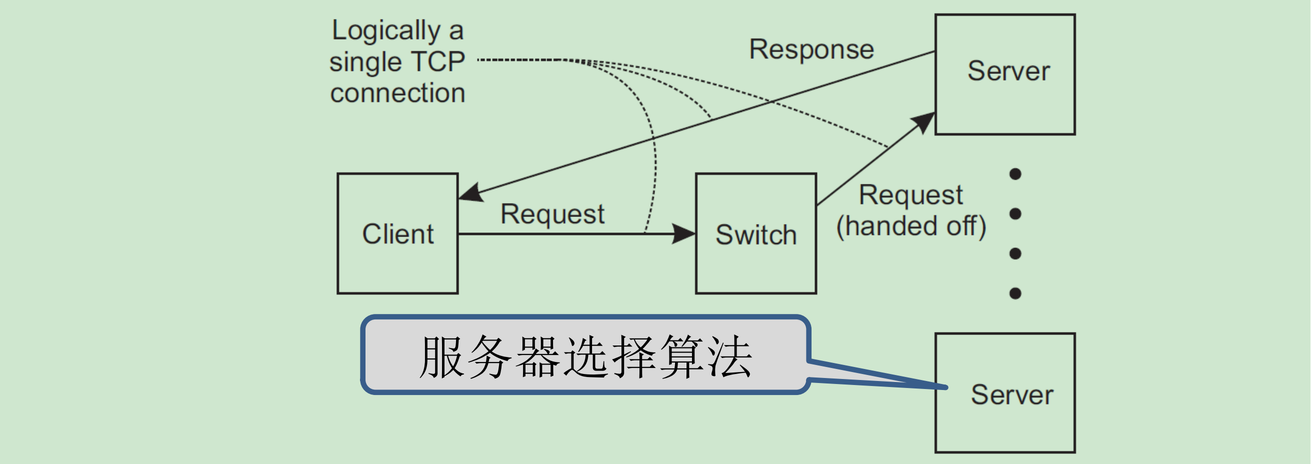

服务器集群

前端容易出现过载的情况：需要一种新的度量方法

- 基于传输层交换方法：前端简单地将TCP请求传递到服务器，只是会考虑某些简单的性能指标如CPU利用率等；
- 基于内容可感知的分派方法：前端会读取请求的内容，然后选择最合适的服务器；

将基于传输层交换和基于内容可感知的分派方法相结合

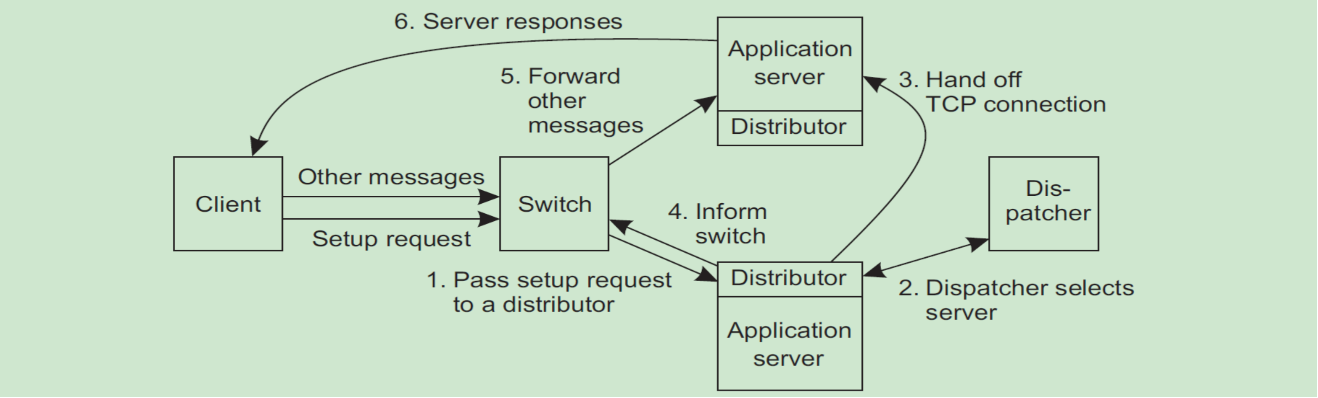

当服务器扩展到整个互联网

➢ 观察发现

将服务器集群扩展到互联网规模可能会引入管理问题。可以通过采用单个云计算商提供的数据中心避免这些问题。

➢ 请求分派：如果局部性比较重要的话

常用的方法是利用DNS:

- 客户端通过DNS查询特定的服务-客户端的IP地址是请求的一部分；
- DNS服务器记录请求服务的副本服务器信息，并且返回大部分本地服务的地址；

➢ 客户透明性

为了保障透明性，DNS resolver会代替客户端，问题是有可能距离远。

分布式服务器访问的稳定性

分布式服务器的基本思想是构造一个可靠的、高性能的、稳定的服务器即实现一个稳定的访问点。

- 具有稳定IPv6地址的分布式服务器

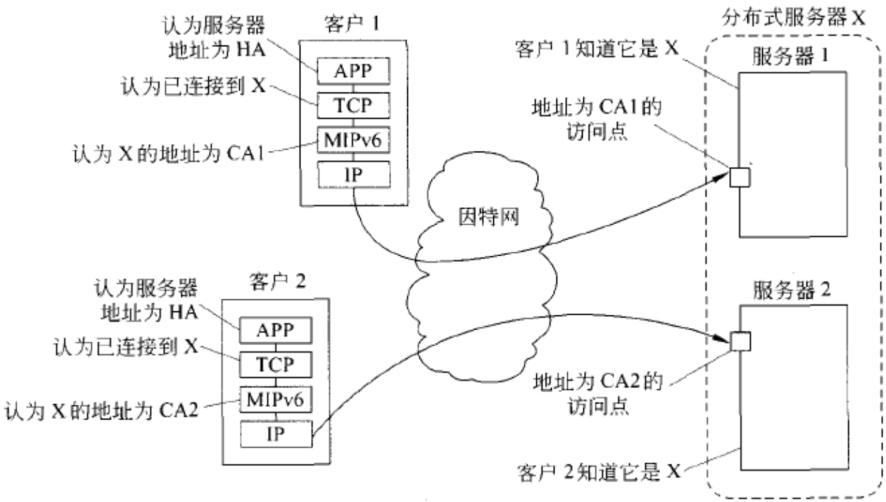

分布式服务器：处理细节

- **本质：客户端具有Mobile IPV6能够透明地跟任意其他节点建立连接**
  - 客户端 C 通过IPv6 与宿主网络 HA 建立连接；
  - HA 被一个宿主代理维护着，HA 可以将连接传递给注册的需要地址 CA；
  - C 可以应用路由优化方法，通过将网络包直接转发到地址 CA（不用传递给宿主agent）；
- **协作分布式系统**
  - 原始的服务器维护一个宿主地址，但是会将连接信息传递给协作节点；
  - 原始节点和协作节点看起来是一个服务器；

管理服务器：PlanetLab

➢ 本质

- 不同的组织贡献机器， 这些机器被共享用于进行各种实验；

➢ 本质

- 我们需要保证不同的分布式应用相互不影响 => 虚拟化

PlanetLab基本的组织结构

➢ 总览

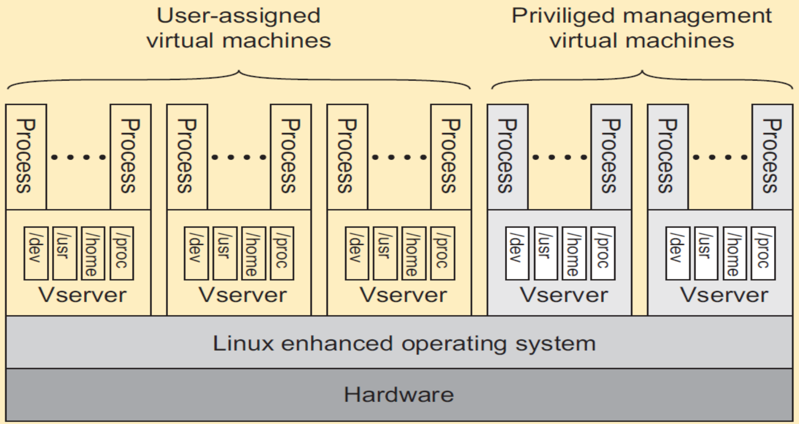

➢ Vserver

- 具有自己的软件库、服务器版本等的独立受保护环境。分布式应用会分发到多个这样的机器上。

代码迁移

➢ 负载分布

- ◻ 确保数据中心中的服务器的复杂运行更加充分（防止浪费能源）
- ◻ 让计算更加贴近数据端，最小化通信代价（例如移动计算）

➢ 灵活性：当需要的时候将代码迁移到客户端

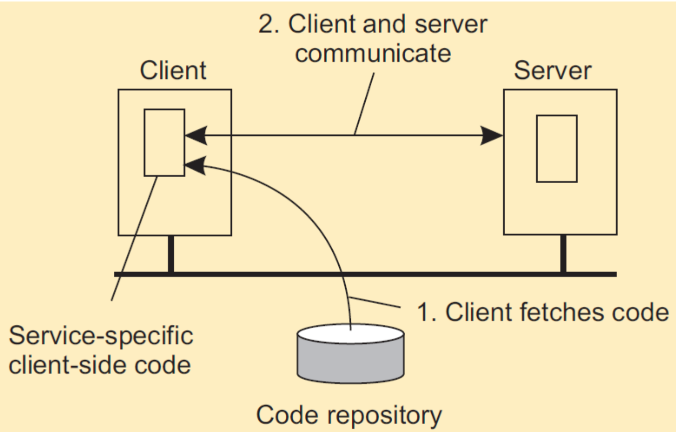

代码迁移的模型

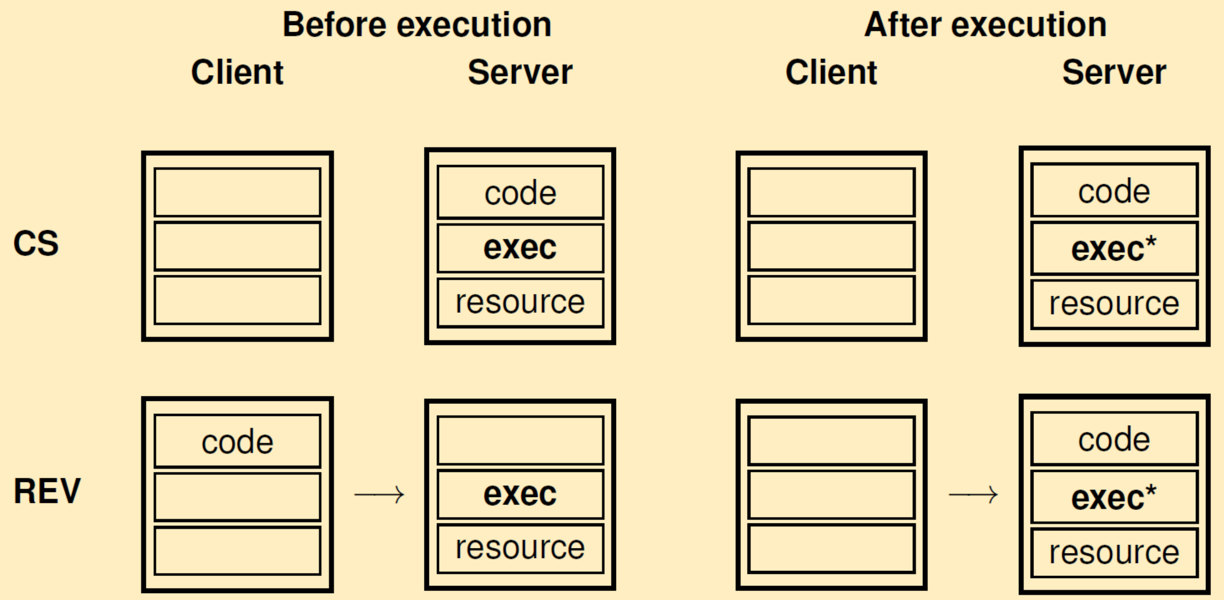

CS: Client-Server

REV: Remote evaluation

代码迁移的模型

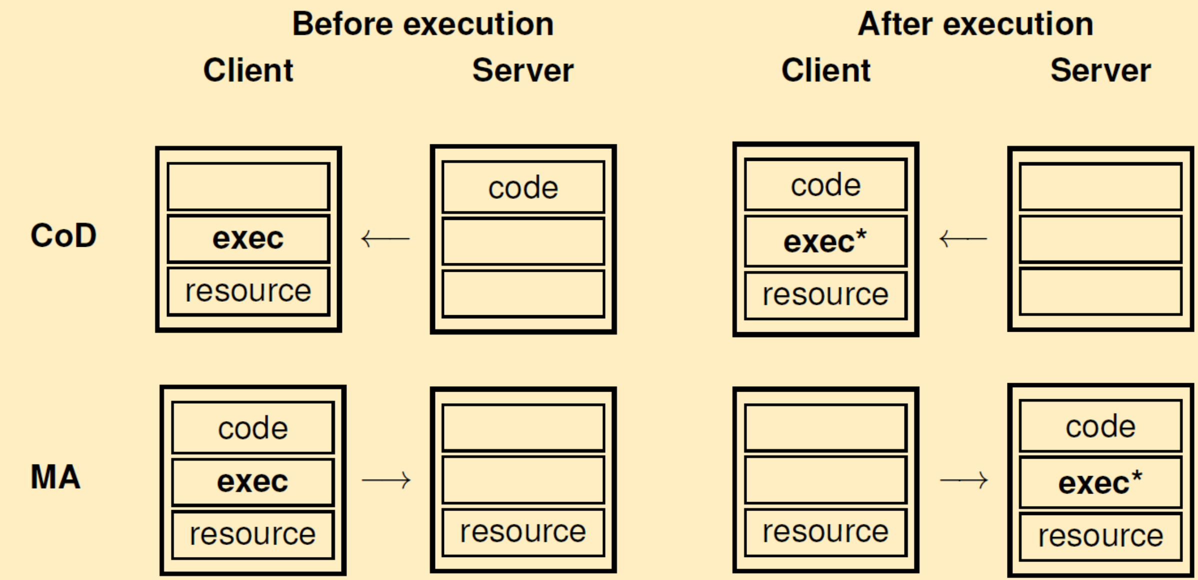

CoD: Code-on-demand　　MA: Mobile agents

强/弱可移动性

➢ 对象组件

- ◻ 代码片段：包含实际执行的代码；
- ◻ 数据片段：包含状态
- ◻ 执行状态：包含线程执行对象代码的上下文；

➢ 弱移动性：仅仅移动代码和数据片段（重启执行）

- ◻ 相对简单，特别是如果代码是可移植的；
- ◻ 需要区分两种模式：代码推送（Push）和代码拉取（Pull）

➢ 强移动性：移动组件，包括执行状态

- ◻ 迁移（Migration）：将整个对象从一个机器移动到另外一个机器；
- ◻ 克隆（Cloning）：开始克隆，将其设置为相同的执行状态；

异构系统中的迁移

➢ 主要问题

- 目标机器可能不适合执行迁移后的代码；
- 进程/线程/处理器的上下文的定义比较依赖于硬件、操作系统和运行时系统；

➢ 仅有的解决方案：在不同的平台上抽象机器的实现

- 解释型语言，拥有自己的VM；
- 虚拟机监控器；

迁移虚拟机

➢ 迁移镜像：三个不同的方案

- 将内存页面推送到新的机器，在迁移过程中重新发送被修改过的页面；
- 停止当前的虚拟机；迁移内存，然后重新启动虚拟机；
- 让新的虚拟机按需拉取内存页面：在新的虚拟机上立即创建进程，并且按需拷贝内存页面；

虚拟机迁移的性能

➢ 问题

一次完整的虚拟机迁移可能需要几十秒。在迁移期间，服务可能处于几秒钟的完全不可用的状态。

➢ 在虚拟机迁移过程中虚拟机响应时间的度量

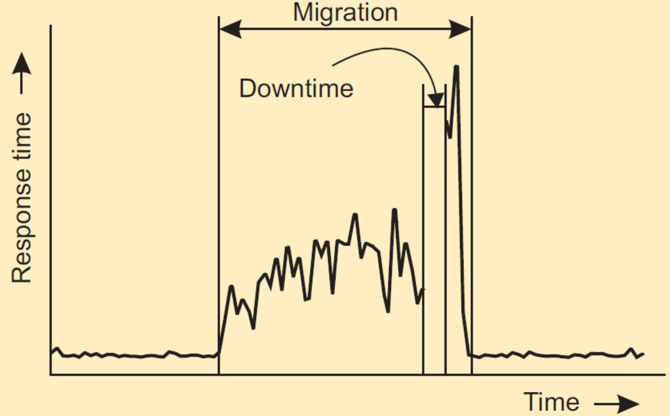

CRIU

在Linux操作系统上实现 checkpoint/Recovery

- ✓ Using this tool, you can freeze a running application (or part of it) and checkpoint it to a hard drive as a collection of files.
- ✓ You can then use the files to restore and run the application from the point it was frozen at.
- ✓ The distinctive feature of the CRIU project is that it is mainly implemented in user space. There are some more projects doing C/R for Linux, and so far CRIU appears to be the most feature-rich and up-to-date with the kernel.

Demo

https://github.com/checkpoint-restore/criu